

Objectifs pédagogiques Master 1ère année

Master Data/IA

UE1 - Socle

SQL Avancé - 42h

Comprendre les concepts fondamentaux des bases de données relationnelles
Apprendre les bases du langage SQL
Comprendre les concepts avancés de SQL : vues, indexations, procédures stockées et leur impact sur la performance
Analyser l'impact des choix de modélisation, d'indexation et de requêtage sur la consommation de ressources (CPU, mémoire, I/O)
Optimiser des requêtes SQL dans une logique de frugalité numérique et de sobriété des traitements
Acquérir une compréhension de la modélisation décisionnelle (schéma en étoile, flocon)
Apprendre les bases de l'administration des bases de données
Identifier les bonnes pratiques de gestion du cycle de vie des données (rétention, archivage, suppression)

Modélisation des données - 21h

Maîtriser les principes clés : séparation des phases conceptuelle, logique et physique
Apprendre à construire et interpréter les principaux modèles MERISE (MCD, MCT, MPD)
Élaborer un schéma de données complet à partir d'un cas pratique
Analyser l'impact des choix de modélisation sur la volumétrie, la redondance et la durabilité des données
Comprendre les limites de MERISE dans des environnements modernes
Connaître les alternatives modernes à MERISE (UML / BPMN)
Comparer différents modèles de données au regard de critères de sobriété, maintenabilité et évolutivité

Préparation et manipulation de données - 42h

Apprendre à utiliser les bibliothèques de manipulation de données sous Python : Pandas, Numpy, etc
Programmer des routines de préparation de données avec Python sous un environnement virtuel
Être capable de créer un jeu de données exploitable à partir d'un jeu de données stable dans l'objectif de les utiliser avec PowerBI ou Tableau
Savoir gérer les problématiques courantes de collecte, nettoyage, traitement et transformation des données avec Python (ex : gestion des valeurs manquantes, données aberrantes, Standardisation / normalisation des données, encodage des variables catégorielles(ex:one-hot encoding), traitement des variables temporelles (dates), ...)
Optimiser les traitements de données en limitant les calculs inutiles, les duplications et les volumes manipulés
Analyser l'impact environnemental de pipelines de préparation de données selon les choix algorithmiques et techniques
Introduire à partir d'un jeu de données préparé, la construction de visualisations et d'indicateurs statistiques

UE1 - Socle

Mathématiques appliquées - 70h

Bases de la statistique descriptive : moyenne, écart-type, médiane, distribution.

Probabilités appliquées (lois normales, binomiales, etc)

Tests d'hypothèses, intervalles de confiance, tests de corrélation

Faire la différence entre Corrélation et Causalité : Spurious Correlation (site web)

Justifier le recours à des méthodes statistiques adaptées afin d'éviter des calculs surdimensionnés ou inutiles

Numérique responsable et écoconception - 23h

Définir les principaux piliers du numérique responsable (écoconception, accessibilité, inclusion, sobriété, éthique...) et en comprendre les enjeux environnementaux et sociétaux

Positionner l'éco-conception comme levier d'action clé, aux côtés de la gouvernance des données, de la durabilité des usages et de l'accessibilité

Expliquer le rôle de l'Analyse de Cycle de Vie (ACV) pour évaluer l'impact global d'un service numérique, de sa conception à sa fin de vie

Comprendre les référentiels RGEN (écoconception) et RGAA (accessibilité) et les mobiliser comme outils d'audit, de conformité et d'amélioration continue

Appliquer les principes d'écoconception pour réduire l'empreinte d'un service numérique existant ou en cours de développement

Structurer un diagnostic d'impact en identifiant les leviers d'action sur le front (interface, navigation), le back (requêtes, flux, pagination, indexation) et l'architecture

Utiliser des outils de benchmark et de mesure d'impact (ex. : EcoIndex, Lighthouse, GreenFrame) pour objectiver les progrès réalisés

UE2 - Data Analyse

Utilisation d'une suite décisionnelle - 14h

Introduire aux outils de Business Intelligence

Construire des tableaux de bord interactifs

Concevoir des tableaux de bord sobres, lisibles et limitant les rafraîchissements et calculs inutiles

Évaluer l'impact des choix de visualisation et de rafraîchissement sur la performance

Data visualisation - 42h

UE2 - Data Analyse

Apprendre à utiliser les bibliothèques de visualisation Python (Matplotlib, Seaborn) pour créer des visualisations percutantes et informatives

Comprendre les principes de l'expérience utilisateur (UX) appliqués à la visualisation de données / Notions de charte graphique

Maîtriser les principes fondamentaux de la visualisation de données pour une présentation claire et efficace des informations

Connaître les différents types de graphiques et leurs usages (histogrammes, diagrammes en barres, nuages de points, etc.), et savoir choisir la visualisation adaptée à la nature des données et au public cible

Savoir interpréter et analyser les visualisations de données pour en extraire des insights utiles

Savoir appliquer des concepts de design visuel (espacement, alignement, hiérarchisation de l'information, couleurs) pour maximiser la lisibilité et l'impact des visualisations

Connaître les bases de la perception visuelle pour concevoir des visualisations optimisées en termes de clarté, de lisibilité et d'esthétique

Concevoir des visualisations accessibles, sobres et conformes aux principes d'écoconception et d'accessibilité

Projet de datavisualisation - 35h

Valider les compétences acquises au cours des modules Python / Data Visualisation précédents

Apprendre à manipuler un Notebook Python pour production de rapport d'analyse

Intégrer des critères de sobriété, d'accessibilité et d'impact environnemental dans les choix de visualisation

UE3 - Data science

Introduction au machine learning - 35h

Comprendre les principaux concepts du Machine Learning : entraînement d'un modèle, évaluation, sur-apprentissage, optimisation, etc

Découvrir les grandes familles de modèles (classification, régression, etc) et des exemples de modèles populaires

Savoir se tourner vers le modèle le plus adapté en fonction du besoin

Apprendre à paramétrer et optimiser son modèle

Expliquer l'intelligence artificielle et en comprendre les enjeux

Comparer différents modèles selon leurs performances et leur coût computationnel

Justifier un choix de modèle dans une logique de frugalité algorithmique

Mise en pratique du machine learning - 35h

Implémenter des modèles avec Python

Évaluer les performances des modèles

Optimiser les pipelines ML en réduisant les itérations, les dimensions et la consommation de ressources

Introduction NLP et Text Mining - 14h

UE3 - Data science

Introduire aux concepts du NLP (Natural Language Processing) et Text Mining

Se familiariser avec les concepts de pré-traitement des données textuelles : Parsing, tokenization, lemmatisation, stop words removal,...

Découvrir les différents modèles de NLP, quels sont les paramètres? Comment régler ces paramètres pour un cas d'usage précis

Potentiellement via un projet d'analyse de sentiments (sentimental analysis) sur du texte

Comparer des approches NLP simples et complexes selon leurs impacts computationnels et environnementaux

Initier au prompt engineering dans une logique d'usage raisonné des LLM

UE4 - Data ingénierie

Méthodes de développement et DevOps - 14h

Etre familier avec les principaux concepts et commandes Git pour le versioning (notions de commits, branches, merges, conflits, ...)

Savoir utiliser GitHub et GitLab pour la gestion de projets collaboratifs, en maîtrisant les pull requests, les issues, et les outils d'intégration continue

Comprendre les principes et les bonnes pratiques de DevOps

Maîtriser les concepts clés d'intégration continue (CI), de déploiement continu (CD), et d'automatisation des processus

Apprendre à configurer et automatiser les pipelines CI/CD sur GitLab et GitHub pour déployer des projets de manière sécurisée et efficace

Acquérir les compétences pour gérer les versions d'un code / projet et assurer la traçabilité des modifications dans un contexte de data engineering / data science

Avoir un aperçu des principaux outils DevOps (Jenkins, Docker, Kubernetes, Ansible, ...) pour l'automatisation de déploiements, la gestion des conteneurs, et le monitoring des applications

Interconnexion/Exploitation des API - 14h

Comprendre le fonctionnement des sites web (notions HTTP, HTML, CSS, XML, ...)

Apprendre les bases du scraping avec Python

Apprendre à se connecter et requêter via une API (Python)

Exploitation des LLM via APIs (OpenAI, Hugging Face)

Outils Cloud et Cloud computing - 21h

Principes Cloud Computing / Modèles de services (IaaS, SaaS), ...

Panorama des principales plateformes cloud : AWS, Azure, GCP

Savoir utiliser une machine virtuelle

Savoir utiliser une instance docker

Avoir des notions de bases en Cloud et savoir que des outils comme AWS, Azure ou Google Cloud existent, savoir y souscrire et comment les utiliser

Adopter des pratiques cloud favorisant la sobriété des ressources

UE5 - Gouvernance

Qualité des données - 14h

UE5 - Gouvernance

Comprendre les enjeux et les dimensions de la qualité des données (exactitude, complétude, cohérence, etc.)

Détecter et analyser les anomalies dans un jeu de données à partir de critères définis

Mettre en œuvre des techniques de nettoyage, de correction et de contrôle de la qualité des données

Utiliser des outils pour automatiser les vérifications et suivre les indicateurs de qualité

Concevoir un processus de gouvernance intégrant l'amélioration continue de la qualité des données

Relier qualité des données, réduction des traitements inutiles et sobriété numérique

UE6 - Ouverture métier

Communication technique et des résultats - 7h

Apprendre à présenter ses résultats de manière efficace

Faire des démos techniques à des profils non tech (marketing, finance etc)

Techniques de storytelling des données